

# Python Cheat Sheet – Statistik mit dem tips-Datensatz

Technische Hochschule Ingolstadt

11. November 2025

## Inhaltsverzeichnis

|          |                                                   |          |
|----------|---------------------------------------------------|----------|
| <b>1</b> | <b>Setup &amp; Daten</b>                          | <b>2</b> |
| <b>2</b> | <b>Stetige Variablen</b>                          | <b>2</b> |
| <b>3</b> | <b>Kategoriale Variablen</b>                      | <b>2</b> |
| <b>4</b> | <b>Zwei kategoriale Variablen</b>                 | <b>3</b> |
| <b>5</b> | <b>Eine kategoriale und eine stetige Variable</b> | <b>3</b> |
| <b>6</b> | <b>Zwei stetige Variablen</b>                     | <b>4</b> |
| <b>7</b> | <b>Interpretationshilfen (Kurz)</b>               | <b>4</b> |

# 1 Setup & Daten

```
import seaborn as sns, pandas as pd, numpy as np
import matplotlib.pyplot as plt
from scipy import stats
from statsmodels.graphics.mosaicplot import mosaic
```

```
df = sns.load_dataset("tips")
df.head()
df.info()
df.describe()
```

**Erklärung:** Lädt den Datensatz, gibt Überblick über Struktur und Kennzahlen.

# 2 Stetige Variablen

## Kennzahlen

```
x = df["total_bill"]
x.mean(), x.median(), x.std()
x.quantile([.25, .5, .75])
```

**Erklärung:** Zentrale Lage- und Streuungsmaße.

## Visualisierung

```
plt.hist(x, bins=20)
sns.boxplot(x=x)
sns.violinplot(y=x)
```

**Erklärung:** Histogramm, Boxplot, Violinplot – Verteilungsform, Ausreißer, Dichte.

## Normalitätsprüfung

```
stats.probplot(x, dist="norm", plot=plt)
stats.shapiro(x)
```

**Erklärung:** QQ-Plot und Shapiro–Wilk-Test prüfen Normalverteilung.

# 3 Kategoriale Variablen

## Häufigkeiten

```
df["sex"].value_counts()
(df["sex"].value_counts(normalize=True)*100)
```

**Erklärung:** Absolute und relative Häufigkeiten.

## Visualisierung

```
sns.countplot(x="day", data=df)
df["smoker"].value_counts().plot.pie(autopct="%.1f%%")
```

**Erklärung:** Balken- und Kreisdiagramm zur Darstellung von Häufigkeiten.

## 4 Zwei kategoriale Variablen

### Kreuztabelle

```
ct = pd.crosstab(df["sex"], df["smoker"])
pd.crosstab(df["sex"], df["smoker"], normalize="index")*100
```

**Erklärung:** Kreuztabelle absolut und prozentual.

### Visualisierung

```
sns.countplot(x="sex", hue="smoker", data=df)
```

**Erklärung:** Gruppiertes Balkenplot zur Verteilung beider Variablen.

### Chi<sup>2</sup>-Test

```
from scipy.stats import chi2_contingency
chi2, p, dof, exp = chi2_contingency(ct)
```

**Erklärung:** Chi<sup>2</sup>-Test prüft, ob ein Zusammenhang zwischen den Kategorien besteht.

### Effektstärke

```
n = ct.to_numpy().sum()
cramers_v = np.sqrt(chi2 / (n * (min(ct.shape) - 1)))
```

**Erklärung:** Effektstärke Cramér's V (0.1 = klein, 0.3 = mittel, 0.5 = groß).

### Mosaikplot

```
mosaic(df, ["sex", "smoker"])
```

**Erklärung:** Flächen zeigen relative Häufigkeiten je Kombination.

## 5 Eine kategoriale und eine stetige Variable

### Deskriptiv

```
df.groupby("time")["total_bill"].describe()
sns.boxplot(x="time", y="total_bill", data=df)
```

**Erklärung:** Kennzahlen und Boxplots je Gruppe (Lunch/Dinner).

### t-Test

```
lunch = df.loc[df["time"]=="Lunch", "total_bill"]
dinner = df.loc[df["time"]=="Dinner", "total_bill"]
t_stat, p_val = stats.ttest_ind(lunch, dinner, equal_var=True)
```

**Erklärung:** t-Test für unabhängige Gruppen ( $p \leq .05 \rightarrow$  signifikanter Unterschied).

## Effektstärke: Cohen's d

```
def cohens_d(x1, x2):  
    n1, n2 = len(x1), len(x2)  
    s1, s2 = np.var(x1, ddof=1), np.var(x2, ddof=1)  
    s_pooled = np.sqrt(((n1-1)*s1 + (n2-1)*s2) / (n1+n2-2))  
    return (np.mean(x1) - np.mean(x2)) / s_pooled
```

**Erklärung:** Cohen's d misst die Stärke des Unterschieds (0.2 klein, 0.5 mittel, 0.8 groß).

## 6 Zwei stetige Variablen

### Visualisierung

```
sns.scatterplot(x="total_bill", y="tip", data=df)  
sns.lmplot(x="total_bill", y="tip", data=df)
```

**Erklärung:** Scatterplot mit Regressionslinie zeigt linearen Trend.

### Pearson-Korrelation

```
r, p = stats.pearsonr(df["total_bill"], df["tip"])
```

**Erklärung:** r misst Stärke (Effektgröße), p testet  $H_0: p = 0$  (kein linearer Zusammenhang).

### Spearman-Korrelation

```
rho_s, p_s = stats.spearmanr(df["total_bill"], df["tip"])
```

**Erklärung:** Rangkorrelation, robust gegenüber Ausreißern und nichtlinearen Beziehungen.

## 7 Interpretationshilfen (Kurz)

- **p-Wert:** Signifikanz ( $p < .05 \rightarrow$  Hinweis auf echten Effekt).
- **Effektstärke:** praktische Bedeutung (Cramér's V, Cohen's d,  $|r|$ ).
- **Voraussetzungen:** Normalität, Varianzgleichheit, Linearität prüfen.